CHALLENGE 1: FAKE NEWS / DESINFORMAÇÃO

IA e pensamento crítico

Análise de Datasets

Grupo 3

Setembro de 2026

Avaliação Técnica de Datasets

Análise executiva de **FakeRecogna**, **FakeRecogna 2.0 Abstrativa** e **FactChecks.br** para classificação de veracidade, score probabilístico e explicabilidade baseada em evidências.

Objetivo da avaliação
Identificar como diferentes bases de dados podem apoiar um sistema capaz de analisar notícias, apresentar confiança calibrada e produzir explicações fundamentadas, sempre preservando a autonomia do usuário.

Princípio orientador

O sistema deve apoiar a verificação de informações sem apresentar sua previsão como uma decisão final. Para isso, precisa distinguir claramente entre **predição do modelo**, **evidências recuperadas** e **interpretação humana**.

Escopo
Datasets em português brasileiro, com foco em processamento de linguagem natural, fact-checking, confiabilidade da informação e estímulo ao pensamento crítico.

Pergunta de projeto

Como oferecer sinais úteis de confiabilidade e contexto sem transformar um resultado probabilístico em um selo automático de “verdadeiro” ou “falso”?

Resumo Executivo

Os três datasets têm papéis complementares. O maior ganho vem de separar o problema em classificação textual, calibração de confiança e recuperação de evidências, evitando tratar a saída do classificador como uma “probabilidade de verdade” absoluta.

Dataset	Escala / foco	Classificação	Explicabilidade	Utilidade principal
FakeRecogna	∼11,9 mil amostras; notícias brasileiras	Binária	Baixa	Baseline e classificador inicial
FakeRecogna 2.0 Abstrativa	∼52,8 mil amostras; maior diversidade	Binária	Baixa a média	Corpus principal de classificação
FactChecks.br	Coleção multi-dataset de fact-checking	Heterogênea / harmonizada	Média a alta	Benchmark, evidências e RAG

Recomendação de arquitetura de dados
Usar o FakeRecogna 2.0 como base principal de treinamento do classificador textual, o FactChecks.br como recurso de benchmark e recuperação de checagens/evidências, e o FakeRecogna original como baseline adicional. O score exibido deve ser calibrado e enriquecido por sinais de fonte, evidência e corroboração.

Atenção ao score percentual
Uma saída 0,87 de softmax ou regressão logística representa a confiança estatística do modelo sob sua distribuição de treinamento. Não deve ser apresentada diretamente como “87% de chance de a notícia ser verdadeira”. O Hub deve aplicar calibração probabilística e combinar o classificador com evidências recuperadas.

Dataset 1 — FakeRecogna

Link oficial: Hugging Face — recogna-nlp/FakeRecogna

1. Visão geral e propósito

O FakeRecogna é um corpus brasileiro para detecção de notícias falsas em português. A classe *fake* foi construída a partir de iniciativas brasileiras de checagem, enquanto a classe real utiliza notícias de veículos e fontes institucionais. O corpus contém aproximadamente 11,9 mil amostras balanceadas e tem forte presença de temas de saúde e política.

2. Aderência aos requisitos do modelo

- **Classificação de veracidade:** binária. Na versão original, `Class = 0` representa *fake* e `Class = 1` representa real. É adequado para um primeiro classificador, mas não ensina diretamente categorias como "parcialmente verdadeira", "enganosa" ou "inconclusiva".
- **Score percentual:** permite treinar um modelo probabilístico e calibrá-lo posteriormente com Platt Scaling, Isotonic Regression ou Temperature Scaling. O dataset não contém percentual humano de veracidade como *ground truth*.
- **Explicabilidade:** limitada. O schema inclui título, subtítulo, texto, categoria, autor, data e URL, mas não estrutura evidências ou justificativas dos checadores.

3. Qualidade técnica e desafios

- Viés temático: saúde e política representam parcela relevante do corpus.
- Risco de *source leakage*: o modelo pode aprender estilo editorial e domínio dos sites em vez de relações factuais.
- Recomenda-se auditar duplicatas, URLs, normalização textual e diferenças entre texto original e texto tratado.

4. Potencial de integração

Seu uso principal é offline, para treinamento e avaliação. Os campos de metadados ajudam a alinhar o corpus com o schema de ingestão de notícias atuais. Para medir generalização em produção, devem ser usados *split* temporal e *source-held-out*, além do *split* aleatório.

Veredito: utilidade média
Adequado como baseline e corpus complementar, mas insuficiente como única fonte para classificação multiclasse ou geração de explicações fundamentadas.

Dataset 2 — FakeRecogna 2.0 Abstrativa

Link oficial: Hugging Face — recogna-nlp/fakerecogna2-abstrativa

1. Visão geral e propósito

O FakeRecogna 2.0 amplia significativamente a primeira versão. A documentação acadêmica descreve cerca de 52,8 mil notícias balanceadas entre conteúdo real e falso, maior diversidade de fontes e expansão de categorias. A versão "abstrativa" aplica sumarização em notícias verdadeiras longas para aproximar o comprimento das classes.

2. Aderência aos requisitos do modelo

- **Classificação de veracidade:** continua binária. Nesta versão, `Label = 0` representa real e `Label = 1` representa *fake*. A codificação é inversa à do FakeRecogna original e deve ser normalizada antes da combinação dos datasets.
- **Score percentual:** a maior escala favorece treinamento e calibração, mas a probabilidade prevista continua sendo confiança do modelo, não uma medida factual direta de "verdade".
- **Explicabilidade:** não há evidências ou justificativas estruturadas. Os resumos abstrativos não devem ser tratados como explicações factuais de *ground truth*.

3. Qualidade técnica e desafios

- A maior cobertura reduz limitações de escala, embora política e saúde ainda tenham volume relevante.
- A sumarização reduz o viés de comprimento, mas pode introduzir um novo sinal: textos gerados ou resumidos automaticamente versus textos provenientes de fact-checking.
- É essencial comparar *random split*, *temporal split* e *source-held-out split*.

4. Potencial de integração

É o candidato mais forte para treinar o classificador textual principal. Continua sendo uma fonte predominantemente offline; a ingestão de notícias atuais exige APIs, RSS, crawlers ou conectores externos. Seu schema preserva URL, data, categoria, autor, título e notícia.

Veredito: utilidade alta
Recomendado para treinamento principal, fine-tuning de BERTimbau/PTT5 e avaliação de generalização temporal e por fonte antes do uso do score em produção.

Dataset 3 — FactChecks.br

Link oficial: GitHub — fake-news-UFG/FactChecks.br

1. Visão geral e propósito

O FactChecks.br é uma coleção padronizada de benchmarks brasileiros de fact-checking. O projeto integra diferentes corpora, como Fake.br, FakeRecogna, Central de Fatos, Fact-check_tweet e FakeNewsSet, reunindo *claims*, checagens, metadados e classificações de fontes distintas.

2. Aderência aos requisitos do modelo

- **Classificação de veracidade:** heterogênea. Os valores não devem ser automaticamente interpretados como uma taxonomia única sem validar a origem de cada subdataset.
- **Score percentual:** útil para calibração e, sobretudo, avaliação *cross-dataset*. Treinar em um corpus e testar em outro fortalece a análise de robustez e generalização.
- **Explicabilidade:** principal destaque. Algumas configurações incluem campos de texto da revisão, autoria, URL, domínio e data, aproximando o corpus da estrutura alegação $\rightarrow$ checagem $\rightarrow$ fonte $\rightarrow$ julgamento.

3. Qualidade técnica e desafios

- Diferentes períodos, fontes, critérios de anotação e schemas exigem normalização rigorosa.
- A deduplicação é obrigatória devido a fontes repetidas e classificações contraditórias entre datasets.
- A preparação deve normalizar textos, URLs, datas, categorias, IDs, labels e similaridade semântica entre alegações.

4. Potencial de integração

É mais valioso como benchmark histórico e camada de conhecimento do que como mecanismo de ingestão em tempo real. As relações entre alegação, revisão, domínio, agência e URL favorecem um pipeline de recuperação de evidências e uma base vetorial de checagens anteriores.

Veredito: utilidade alta
Recomendado para benchmarking de explicabilidade, generalização cross-dataset, recuperação de evidências e avaliação da camada de explicação, respeitando o schema e os critérios de cada subdataset.

Comparação e Recomendação para o Hub

Critério	FakeRecogna	FakeRecogna 2.0	FactChecks.br
Classificação base	Boa	Muito boa	Boa / heterogênea
Escala	Média	Alta	Variável
Multiclasse nativo	Não	Não	Não padronizado
Score calibrável	Sim	Sim	Sim
Evidências / reviews	Limitado	Limitado	Melhor cobertura
Generalização cross-dataset	Limitada	Média	Alta
Ingestão em tempo real	Não	Não	Não
Uso recomendado	Baseline	Classificador principal	RAG + benchmark

Divisão recomendada de responsabilidades
FakeRecogna 2.0 → O que o classificador prevê?
FactChecks.br → Quais checagens e evidências sustentam ou contradizem essa previsão?
Calibração + fonte + evidência + corroboração → Quão seguro o sistema está para apresentar esse julgamento?

Pipeline de treinamento recomendado

- Padronizar labels e schemas, com auditoria explícita das convenções 0/1.
- Deduplicar por URL, hash e similaridade semântica antes de definir os splits.
- Treinar baseline clássico e modelo contextual, avaliando também por tempo e fonte.
- Calibrar probabilidades em validação separada e reportar Brier Score, ECE e curvas de confiabilidade.

Pipeline de inferência recomendado

- O classificador textual produz probabilidade calibrada por classe.
- A recuperação busca checagens anteriores, fontes primárias e evidências relacionadas.
- O módulo de confiabilidade combina probabilidade, qualidade de fonte, evidência e corroboração.
- A IA gera explicação com referências e explicita limitações ou conflitos entre sinais.
- Casos de baixa confiança devem ser encaminhados para revisão humana.

Diretrizes de IA e Pensamento Crítico

1. **Não decidir pelo usuário.** Apresentar resultados como apoio à análise, evitando selos definitivos quando as evidências forem insuficientes.
2. **Separar previsão e evidência.** Informar o que veio do classificador, o que foi recuperado de fontes externas e o que permanece incerto.
3. **Explicar o score.** Mostrar que confiança estatística não equivale a percentual objetivo de verdade.
4. **Promover verificabilidade.** Exibir fontes, datas, autoria, trechos relevantes e links para que o usuário possa conferir o raciocínio.
5. **Sinalizar divergências.** Evidenciar quando fontes confiáveis discordam ou quando uma afirmação ainda não possui checagem suficiente.
6. **Oferecer caminhos de investigação.** Sugerir perguntas críticas: Quem publicou? Qual é a fonte primária? Há confirmação independente? O conteúdo está atualizado?
7. **Manter supervisão humana.** Reservar decisões sensíveis e casos ambíguos para revisão, feedback e contestação.

Mensagem recomendada na interface
"Esta análise é um apoio à verificação, não uma decisão final. Consulte as evidências, considere o contexto e compare fontes antes de formar sua conclusão."

Conclusão

Nenhum dos três datasets, isoladamente, satisfaz todos os requisitos do Hub. A combinação **FakeRecogna 2.0 + FactChecks.br** é a estratégia mais aderente: o primeiro fortalece a classificação textual; o segundo aproxima o sistema de um fact-checking baseado em evidências e explicações. O FakeRecogna original permanece útil como baseline e referência histórica.

O valor do projeto está menos em automatizar um veredito e mais em organizar sinais, evidências e incertezas de modo compreensível. Assim, a IA funciona como instrumento de investigação e não como substituta do pensamento crítico.

Referências e Links Oficiais

[1] **FakeRecogna — Hugging Face**

https://huggingface.co/datasets/recogna-nlp/FakeRecogna

Dataset original em português brasileiro.

[2] **FakeRecogna 2.0 Abstrativa — Hugging Face**

https://huggingface.co/datasets/recogna-nlp/fakerecogna2-abstrativa

Versão ampliada e abstrativa do corpus.

[3] **FakeRecogna 2.0 — artigo PROPOR 2024**

https://aclanthology.org/2024.propor-1.9.pdf

Artigo acadêmico com metodologia, expansão do corpus e experimentos.

[4] **FactChecks.br — GitHub**

https://github.com/fake-news-UFG/FactChecks.br

Repositório da coleção padronizada de datasets brasileiros de fact-checking.

[5] **FactChecks.br — builder no Hugging Face**

https://huggingface.co/datasets/fake-news-UFG/FactChecksbr/blob/main/FactChecksbr.py

Schema e implementação de carregamento das configurações e subdatasets.