CHALLENGE 1: FAKE NEWS / DESINFORMAÇÃO

Análise exploratória de datasets brasileiros

para classificação de notícias falsas

Qualidade, vieses, duplicidade e prevenção de vazamento

Resumo executivo

Este relatório apresenta a aquisição, caracterização, análise de qualidade e análise exploratória de corpora brasileiros destinados à classificação de notícias falsas e verdadeiras. Foram examinados os benchmarks do FactChecks.br e o FakeRecogna em sua distribuição original. A etapa prioriza reprodutibilidade, rastreabilidade e prevenção de vazamento de dados, sem treinamento de modelos ou particionamento prematuro.

Foram analisados 42.591 registros provenientes de 6 datasets ou subconjuntos. A análise encontrou 11.877 assinaturas compartilhadas entre fontes, 132 conflitos semânticos nessas sobreposições e 234 pares candidatos a quase duplicata. Além disso, fonte, autor, período, comprimento e marcadores editoriais apresentam associação relevante com os labels.

Esses resultados indicam risco alto de vazamento e de aprendizado de atalhos. A recomendação central é não executar divisão aleatória por linha. Antes do treinamento, deve-se definir a unidade de predição, revisar conflitos e criar grupos por notícia, URL e similaridade textual.

1 Introdução

O objetivo de longo prazo do projeto é construir um sistema para analisar notícias em português brasileiro, emitir uma classificação, estimar a probabilidade produzida pelo classificador e fornecer evidências e explicações. A presente etapa não busca maximizar acurácia. Seu propósito é compreender as fontes, identificar problemas de qualidade e definir condições metodológicas para experimentos posteriores.

O escopo inclui 6 datasets ou subconjuntos, com 42.591 registros contados separadamente. Esse total não representa notícias únicas, pois há versões e sobreposições entre as fontes.

2 Fontes de dados

2.1 FactChecks.br

O FactChecks.br [1] reúne benchmarks brasileiros com tarefas e schemas distintos. Foram inspecionados Fake.br, FakeRecogna, Central de Fatos, Fact-check Tweet PT e FakeNewsSet. O release contém ainda os arquivos `fake_br.tsv` e `fakebr.tsv`, que possuem o mesmo checksum SHA-256. Ambos foram preservados na camada bruta, mas o alias não foi contado duas vezes. As datas apresentadas neste relatório são as efetivamente observadas e parseáveis nos arquivos, podendo divergir dos períodos resumidos nas páginas de apresentação das fontes. Essa divergência deve ser tratada como evidência de qualidade a ser auditada.

2.2 FakeRecogna

O FakeRecogna [2] disponibiliza título, subtítulo, notícia, categoria, data, autor, URL e classe. A fonte independente contém 11.903 linhas, enquanto a versão incorporada ao FactChecks.br contém 11.773 registros e outro schema. As versões foram mantidas separadas.

Tabela 1: Resumo dos datasets analisados.

Dataset	Registros	Labels brutos
FakeNewsSet	598	-1, 1
FakeRecogna (FactChecks.br)	11.773	-1, 1
Central de Fatos	10.461	-1, 0, 1
Fact-check Tweet PT	656	-1, 1
Fake.br	7.200	-1, 1
FakeRecogna original	11.903	0.0, 1.0

3 Arquitetura e reprodutibilidade

Os dados foram organizados em três camadas: `data/raw`, imutável e contendo os arquivos exatamente como adquiridos; `data/interim`, com um arquivo Parquet padronizado por dataset; e `data/processed`, reservado para a futura base de modelagem. Todas as transformações são implementadas em funções de `src/` e executadas pelo pipeline reprodutível.

Os dados brutos possuem um manifesto com tamanho, origem e SHA-256. Código, notebooks, configurações e relatório são versionados com Git. A arquitetura está preparada para versionamento futuro dos dados com DVC e dos experimentos com MLflow.

4 Metodologia

4.1 Qualidade e normalização

Foram avaliados valores ausentes, duplicatas completas, títulos, textos, URLs, labels, datas, autores, categorias, fontes e domínios. Os labels brutos foram preservados. No FactChecks.br, a documentação representa `1` como `fake`, `-1` como `not_fake` e `0` como `other`. No FakeRecogna original, `0` significa `fake` e `1` significa `real`. A classe `other` não foi convertida automaticamente para uma classe binária.

Tabela 2: Distribuição dos labels por dataset.

Dataset	Label bruto	Semântica	n	Proporção
FakeNewsSet	-1	not_fake	298	49.8%
FakeNewsSet	1	fake	300	50.2%
FakeRecogna (FactChecks.br)	-1	not_fake	5.951	50.5%
FakeRecogna (FactChecks.br)	1	fake	5.822	49.5%
Central de Fatos	-1	not_fake	141	1.3%
Central de Fatos	0	other	34	0.3%
Central de Fatos	1	fake	10.286	98.3%
Fact-check Tweet PT	-1	not_fake	256	39.0%
Fact-check Tweet PT	1	fake	400	61.0%
Fake.br	-1	not_fake	3.600	50.0%
Fake.br	1	fake	3.600	50.0%
FakeRecogna original	0	fake	5.951	50.0%
FakeRecogna original	1	real	5.951	50.0%
FakeRecogna original	ausente	ausente	1	0.0%

4.2 Características textuais e vocabulário

Para cada texto aplicável, foram calculados número de caracteres, palavras, sentenças, exclamações, interrogações, URLs, números e percentual de letras maiúsculas, além do comprimento do título. O vocabulário foi analisado por frequência, unigramas, bigramas e TF-IDF. Stopwords, stemming e lematização não foram aplicados nesta fase para não ocultar artefatos da coleta.

4.3 Duplicatas e similaridade

Duplicatas cruzadas foram identificadas por URL normalizada e hash do texto normalizado. Candidatos quase duplicados foram gerados por TF-IDF de n-gramas de caracteres e similaridade de cosseno mínima de 0,96. Esses pares são evidências para revisão e agrupamento, não remoções automáticas.

5 Resultados

5.1 Distribuição das classes

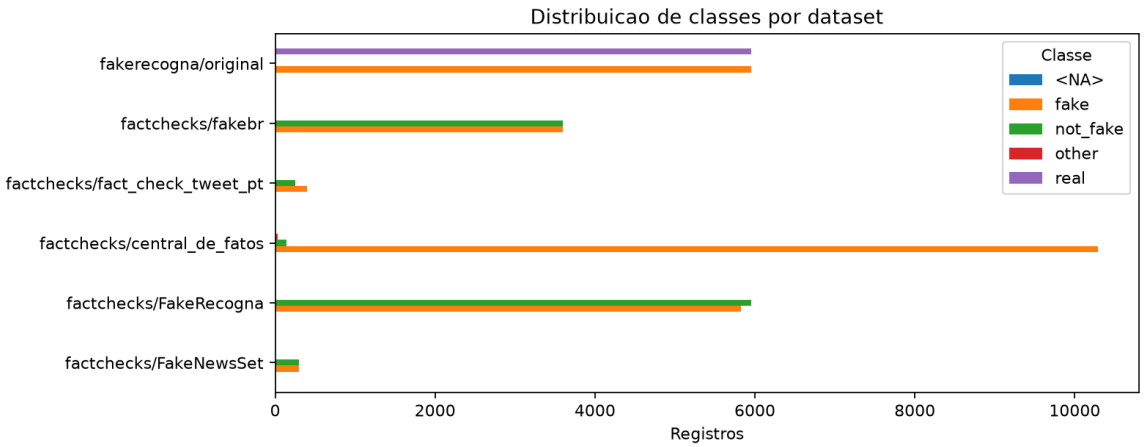


Figura 1: Distribuição dos labels semânticos em cada dataset.

O Central de Fatos apresenta 98,3% dos registros na classe `fake`. Essa concentração inviabiliza o uso de acurácia isoladamente e exige métricas macro, análise por classe e uma definição explícita da tarefa.

5.2 Características textuais

Tabela 3: Medianas de atributos textuais por classe.

Dataset	Classe	Palavras	Caracteres	Maiúsculas
FakeRecogna (FactChecks,br)	fake	96,0	618,0	1,48%
FakeRecogna (FactChecks,br)	not_fake	110,0	738,0	0,58%
Central de Fatos	fake	587,0	3450,0	4,03%
Central de Fatos	not_fake	554,0	3376,0	4,19%
Central de Fatos	other	294,5	1820,0	4,31%
Fake,br	fake	157,0	952,0	4,44%
Fake,br	not_fake	922,0	5580,0	3,94%
FakeRecogna original	fake	60,0	409,0	0,00%
FakeRecogna original	real	91,0	626,0	0,00%

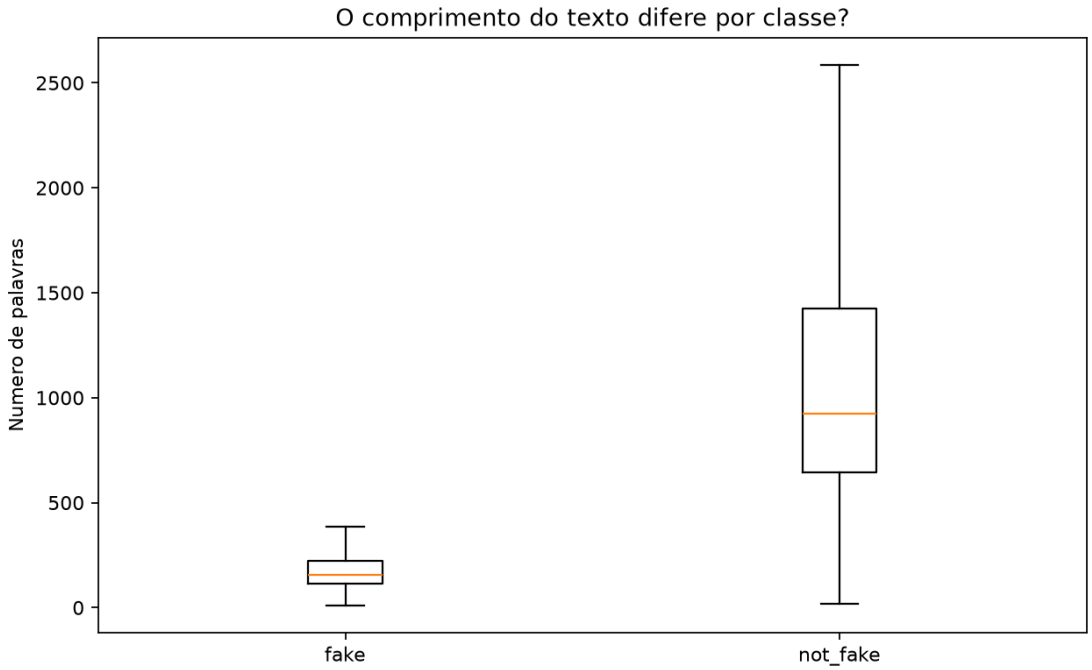


Figura 2: Comprimento textual por classe no Fake.br.

Evidência: No Fake.br, a mediana é 157 palavras para textos falsos e 922 para textos não falsos. **Interpretação:** O comprimento está fortemente associado à classe e reflete diferenças do processo de coleta. **Possível impacto:** Um classificador pode alcançar desempenho elevado usando tamanho, sem aprender propriedades transferíveis do conteúdo.

No FakeRecogna consolidado, termos como “boato”, “fake”, “WhatsApp” e “rede social” aparecem entre os mais distintivos da classe falsa. Eles podem representar marcadores editoriais de checagem ou canais de disseminação, e não evidência factual generalizável.

5.3 Duplicatas e sobreposição

Tabela 4: Linhas envolvidas em duplicação por campo.

Dataset	Título	Texto	URL
FakeNewsSet	0	0	10
FakeRecogna (FactChecks.br)	0	0	350
Central de Fatos	0	0	0
Fact-check Tweet PT	0	0	218
Fake.br	0	4	34
FakeRecogna original	470	32	352

Foram encontradas 11.877 assinaturas compartilhadas entre datasets, das quais 132 têm semântica de label conflitante após equiparar `not_fake` e `real` apenas para comparação. Dentro dos datasets, foram identificados 234 pares candidatos a quase duplicata, incluindo 3 conflitos de classe.

Evidência: Há ampla sobreposição exata e aproximada entre fontes. **Interpretação:** A linha não é uma unidade independente de amostragem. **Possível impacto:** Um split aleatório por linha pode colocar a mesma notícia, ou versões dela, em treino e teste, inflando as métricas.

5.4 Fontes, autores e atalhos

No Fake.br, 99,8% dos registros estão em domínios frequentes exclusivos de uma classe. No FakeRecogna original, 50,1% dos registros pertencem a autores frequentes associados a uma única classe.

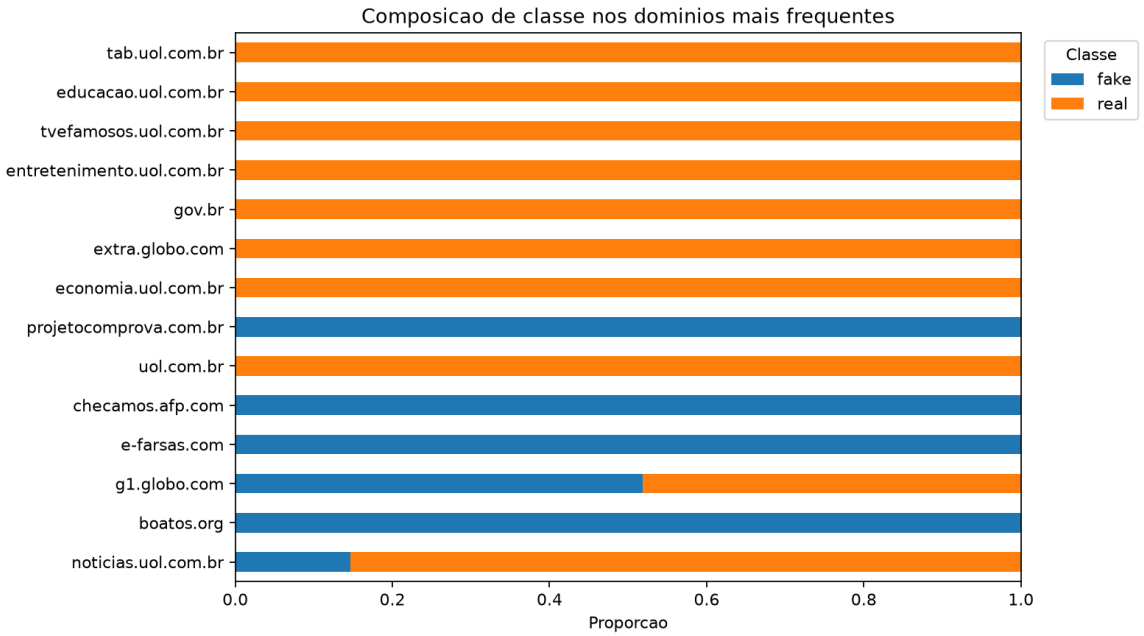


Figura 3: Composição de classe nos domínios mais frequentes do FakeRecogna original.

Evidência: Domínios e autores apresentam elevada pureza de classe. **Interpretação:** A origem da notícia atua como proxy do rótulo. **Possível impacto:** O modelo pode reconhecer o portal ou o estilo editorial em vez de avaliar sinais relacionados ao conteúdo.

6 Riscos de viés e vazamento

A severidade é operacional: alta quando o atalho cobre grande parcela da base ou pode transferir a mesma notícia entre folds; média quando o risco é localizado ou depende do split; e baixa quando a evidência possui cobertura pequena. A classificação não é um julgamento moral sobre fontes jornalísticas.

Tabela 5: Riscos classificados com severidade alta.

Risco	Evidência	Recomendação
Associação entre label e domínio em FakeNewsSet	72,4% dos registros estão em valores com pelo menos 5 casos e uma única classe.	Auditar e considerar divisão em grupos por domínio; comparar baselines com e sem o campo.
Associação entre label e domínio em Central de Fatos	57,9% dos registros estão em valores com pelo menos 5 casos e uma única classe.	Auditar e considerar divisão em grupos por domínio; comparar baselines com e sem o campo.
Associação entre label e categoria em Central de Fatos	66,8% dos registros estão em valores com pelo menos 5 casos e uma única classe.	Auditar e considerar divisão em grupos por categoria; comparar baselines com e sem o campo.
Separação temporal entre classes em Central de Fatos	O início das classes difere em até 766 dias; consultar a tabela de períodos.	Testar divisão temporal e medir o desempenho por janela de tempo.
Associação entre label e domínio em Fake.br	99,8% dos registros estão em valores com pelo menos 5 casos e uma única classe.	Auditar e considerar divisão em grupos por domínio; comparar baselines com e sem o campo.
Separação temporal entre classes em Fake.br	O início das classes difere em até 1200 dias; consultar a tabela de períodos.	Testar divisão temporal e medir o desempenho por janela de tempo.
Associação entre label e autor em FakeRecogna original	50,1% dos registros estão em valores com pelo menos 5 casos e uma única classe.	Auditar e considerar divisão em grupos por autor; comparar baselines com e sem o campo.
Separação temporal entre classes em FakeRecogna original	O início das classes difere em até 2650 dias; consultar a tabela de períodos.	Testar divisão temporal e medir o desempenho por janela de tempo.

Risco	Evidência	Recomendação
Sobreposição entre datasets	11877 assinaturas cruzadas; 132 apresentam conflito semântico de label.	Agrupar por URL ou texto antes da divisão e revisar conflitos; nunca sortear linhas isoladamente.

7 Estratégias futuras de preparação

Três alternativas permanecem em aberto:

A. **Datasets separados:** preserva a tarefa, a taxonomia e o processo de coleta de cada corpus, favorecendo diagnóstico intradomínio.
B. **Combinação de subconjuntos compatíveis:** amplia a cobertura, mas exige alinhar unidade textual e labels, revisar conflitos e formar grupos de duplicidade.
C. **Treino em uma fonte e teste externo em outra:** mede transferência, mas exige descontaminação completa e equivalência da tarefa.

Não se recomenda `train_test_split` por linha. As opções futuras incluem split estratificado após agrupamento, group split por notícia ou fonte, split temporal e dataset externo como holdout. O split estratificado preserva proporções, mas não resolve duplicatas; o group split reduz vazamento; o temporal avalia drift; e o holdout externo avalia generalização entre coletas.

8 Baselines e avaliação futura

Os primeiros experimentos recomendados são: TF-IDF com Regressão Logística, TF-IDF com SVM Linear e Bag-of-Words com Regressão Logística. São modelos rápidos, auditáveis e adequados para estabelecer uma referência antes de BERTimbau ou outros Transformers.

Devem ser reportadas Accuracy, Precision, Recall, F1, Macro-F1, matriz de confusão, ROC-AUC e PR-AUC quando aplicáveis. Accuracy não deve ser utilizada isoladamente.

A probabilidade produzida por `predict_proba()` não representa automaticamente a confiabilidade factual da notícia. Ela é uma estimativa condicionada ao classificador e aos dados de treinamento. Estudos futuros devem incluir Brier Score, Log Loss, diagramas de confiabilidade, Platt Scaling e Isotonic Regression.

9 Limitações

- Os datasets representam fontes, períodos e critérios editoriais específicos.
- Metadados ausentes não foram inferidos externamente.
- Candidatos quase duplicados podem conter falsos positivos e falsos negativos.
- Textos de checagem, alegações e notícias originais não são unidades equivalentes.
- Associação entre fonte e label não prova causalidade nem confiabilidade factual.
- O total agregado inclui versões sobrepostas e não define um corpus combinado.

10 Conclusão

A análise confirma que prevenção de leakage deve preceder qualquer treinamento. A forte associação entre classe, fonte, autor, comprimento e vocabulário editorial torna um split aleatório por linha metodologicamente inadequado. A próxima etapa deve definir a unidade de predição, revisar conflitos, construir um identificador de grupo por notícia e só então selecionar uma estratégia de avaliação e implementar os baselines.

A Reprodução da análise

Na raiz do projeto:

```
python3 -m venv .venv
source .venv/bin/activate
python -m pip install -e ".[dev]"
python -m src.analysis.pipeline
```

```
python scripts/generate_latex_report.py
```

Para compilar localmente:

```
cd reports/latex
latexmk -pdf -interaction=nonstopmode eda_report.tex
```

O pacote `eda_report_overleaf.zip`, criado pelo mesmo gerador, pode ser enviado diretamente ao Overleaf.

Fontes e materiais de apoio

[1] Gomes, J. R. S. *FactChecks.br: Collection of Portuguese Fact-Checking Benchmarks*. Disponível em: https://github.com/fake-news-UFG/FactChecks.br. DOI: https://doi.org/10.57967/hf/1016.

[2] Garcia, G. L.; Afonso, L. C. S.; Papa, J. P. *FakeRecogna: A New Brazilian Corpus for Fake News Detection*. PROPOR, 2022. DOI: https://doi.org/10.1007/978-3-030-98305-5_6.

[3] Silva, R. M. et al. *Towards Automatically Filtering Fake News in Portuguese*. Expert Systems with Applications, v. 146, 2020. DOI: https://doi.org/10.1016/j.eswa.2020.113199.