CHALLENGE 1: FAKE NEWS / DESINFORMAÇÃO

IA como apoio à avaliação da confiabilidade da informação

Problema, critérios de confiança e proposta de produto

Resumo executivo

Este relatório organiza a investigação do Grupo 3 sobre como sistemas de inteligência artificial podem ajudar pessoas a avaliar a confiabilidade de informações sem substituir sua autonomia e seu pensamento crítico. A proposta é desenvolver um ambiente digital que analise uma notícia, apresente sinais de confiabilidade, recupere fontes e evidências e ofereça caminhos para que o próprio usuário verifique a informação.

O produto não deve emitir um selo definitivo de "verdadeiro" ou "falso". Seu resultado precisa separar claramente: (i) a previsão estatística do modelo; (ii) a qualidade das fontes; (iii) as evidências localizadas; (iv) a corroboração independente; e (v) as incertezas e limitações da análise. Assim, uma porcentagem exibida representa confiança do sistema sob critérios declarados, e não uma probabilidade absoluta de verdade factual.

Como referência de boas práticas, a investigação adota os princípios da International Fact-Checking Network (IFCN): imparcialidade, transparência das fontes, transparência organizacional, transparência metodológica e política aberta de correções. Esses princípios orientam duas avaliações complementares: uma matriz para a confiabilidade da informação e outra para a confiabilidade do processo e do modelo de IA.

Pergunta central

Como sistemas de IA podem apoiar a avaliação da confiabilidade de informações, apresentando evidências e incertezas de forma compreensível, sem induzir o usuário a aceitar automaticamente uma conclusão?

1 Contexto, problema e objetivo

A desinformação circula em diferentes formatos: conteúdo inteiramente fabricado, conteúdo manipulado, informação verdadeira fora de contexto, manchetes enganosas, sátira interpretada como fato e alegações sem evidência verificável. A velocidade de circulação e o apelo emocional dessas mensagens dificultam a verificação cuidadosa, especialmente em redes sociais e aplicativos de mensagens.

O problema de produto não é apenas detectar padrões linguísticos associados a notícias falsas. É auxiliar o usuário a investigar uma afirmação: identificar quem publicou, localizar a fonte original, examinar as evidências, comparar versões independentes, verificar a data e reconhecer sinais de linguagem tendenciosa. Uma resposta puramente binária pode criar falsa segurança e transferir para a IA uma decisão que exige contexto e julgamento humano.

O objetivo é conceber um *hub* de verificação assistida capaz de:

- receber texto, título ou endereço de uma notícia;
- identificar autoria, veículo, data e origem da afirmação;
- localizar evidências, documentos e checagens relacionadas;
- comparar a informação com fontes independentes;
- analisar linguagem, contexto e indicadores de risco;
- apresentar resultados graduais e justificáveis;
- estimular o usuário a consultar as fontes e formar sua própria conclusão.

1.1 Público-alvo e pesquisa com usuários

O público-alvo inicial é formado por pessoas que consomem notícias em portais, redes sociais e aplicativos de mensagens e desejam fazer uma verificação rápida sem domínio técnico de jornalismo ou ciência de dados. Estudantes, educadores e comunicadores constituem públicos secundários relevantes.

Uma pesquisa de campo deve investigar como essas pessoas verificam informações hoje, quais sinais geram confiança ou desconfiança e que tipo de explicação consideram útil. O questionário deverá evitar pressupor que o usuário já verifica notícias e incluir situações concretas de decisão.

Tabela 1: Questões orientadoras para a pesquisa com usuários.

Tema	**Questões de investigação**
Prática atual	Como a pessoa verifica uma notícia? Compara fontes? Consulta agências de checagem? Encaminha a alguém?
Sinais de confiança	O que pesa mais: veículo, autoria, número de fontes, dados, linguagem, recomendação social ou familiaridade?
Interação com IA	Em que etapa a IA seria útil? Que explicação evitaria confiança cega?
Apresentação	O usuário prefere escala, categorias, lista de evidências ou perguntas guiadas? Como interpreta uma porcentagem?
Autonomia	Depois da análise, a pessoa se sente incentivada a verificar as fontes ou apenas aceita o resultado?

2 Roteiro de verificação da informação

O sistema deve transformar a verificação em um percurso compreensível. Cada etapa produz evidências observáveis, perguntas adicionais e um nível de incerteza; nenhuma etapa isolada determina a conclusão.

2.1 Fonte e autoria

Devem ser identificados o veículo, a fonte original, o autor e sua relação com o tema. Também devem ser examinados o histórico de correções, possíveis conflitos de interesse e a distância entre a publicação analisada e o acontecimento ou documento primário.

Perguntas principais: quem publicou? A fonte pode ser consultada? Existe autoria verificável? O autor possui conhecimento pertinente? A publicação apresenta financiamento, organização ou interesses relevantes?

2.2 Evidências e verificabilidade

A análise deve localizar dados, documentos, estudos, imagens, vídeos ou depoimentos usados para sustentar a alegação. Não basta contar links: é necessário verificar se são acessíveis, relevantes, atuais e suficientemente robustos. Quando possível, o usuário deve conseguir reproduzir o caminho entre a evidência e a conclusão.

2.3 Contexto e atualidade

Uma informação pode ser tecnicamente verdadeira e ainda assim enganar quando apresentada fora de contexto. O sistema deverá observar data, local, recortes, omissões relevantes e consistência com o material original. Conteúdo antigo republicado como recente deve ser explicitamente sinalizado.

2.4 Corroboração independente

A existência de múltiplas páginas repetindo o mesmo conteúdo não constitui confirmação independente. O sistema deverá distinguir fontes que apenas reproduzem uma origem comum daquelas que realizaram apuração própria ou consultaram evidências distintas. Versões contraditórias também devem ser exibidas.

2.5 Linguagem e indicadores de risco

Título sensacionalista, linguagem alarmista ou emocional, erros ortográficos recorrentes, autoria anônima e incompatibilidade entre título e corpo são motivos para investigar, mas não provam falsidade. Esses elementos devem aparecer como *indicadores de risco*, separados das evidências positivas de confiabilidade.

Princípio de interface

Indicadores linguísticos levantam perguntas; fontes e evidências sustentam conclusões. O sistema não deve classificar uma notícia como falsa apenas por seu estilo de escrita.

3 Princípios de fact-checking

A IFCN, vinculada ao Poynter Institute, propõe um código de princípios para avaliar a qualidade do processo de checagem [1]. O código não é uma lista automática de regras para decidir se uma notícia é verdadeira. Ele descreve compromissos que tornam a verificação auditável e confiável.

Tabela 2: Aplicação dos princípios da IFCN ao projeto.

Princípio	Aplicação proposta
Imparcialidade e equidade	Aplicar os mesmos critérios independentemente de pessoa, partido, veículo ou posição defendida.
Transparência das fontes	Exibir links, autoria, datas e trechos para que o usuário possa conferir as evidências.
Transparência de financiamento e organização	Informar responsáveis pelo produto, parceiros, financiadores e possíveis conflitos de interesse.
Transparência da metodologia	Explicar coleta, critérios, pesos, modelos, versões e limites do processo de classificação.
Política aberta de correções	Registrar alterações, incorporar novas evidências e permitir contestação fundamentada.

Os princípios geram perguntas operacionais: a fonte original está identificada? É possível compreender como a informação foi analisada? O mesmo padrão é aplicado a fontes diferentes? Novas evidências podem alterar o resultado? A afirmação possui evidências acessíveis ao usuário?

4 Matriz de confiança da informação

A matriz abaixo converte as dimensões investigadas em critérios observáveis. A escala proposta vai de 0 a 4, em que 0 indica ausência de evidência ou risco grave; 1, evidência fraca; 2, evidência parcial; 3, evidência consistente; e 4, evidência forte e verificável.

Os pesos são uma **hipótese inicial** e deverão ser validados com especialistas, análise hierárquica de processos (AHP) e testes com usuários [2]. A pontuação não substitui a leitura das evidências nem deve ocultar divergências entre critérios.

Tabela 3: Matriz preliminar de confiança da informação.

Dimensão	Peso	Critérios observáveis
Qualidade das fontes	25%	Identificação, proximidade do fato, autoridade no tema, histórico e conflitos de interesse.
Evidências e verificabilidade	25%	Existência, acesso, relevância, robustez e possibilidade de reprodução da análise.
Corroboração independente	20%	Confirmação por fontes realmente independentes e confiáveis; presença de versões contraditórias.
Contexto e consistência	15%	Contexto correto, ausência de omissões materiais e compatibilidade com dados disponíveis.
Atualidade e correção	10%	Data identificável, informação atualizada e existência de correção ou atualização.
Linguagem e coerência editorial	5%	Correspondência entre título e conteúdo; ausência de manipulação linguística evidente.
Total	**100%**	Resultado acompanhado das evidências e da incerteza de cada dimensão.

Uma formulação inicial para o índice é

$$C_{\text{info}} = 100 \sum_{i=1}^{6} w_i \frac{s_i}{4},$$

em que w_i é o peso normalizado da dimensão e $s_i \in \{0, 1, 2, 3, 4\}$ é sua pontuação. Se faltarem dados essenciais, o sistema não deverá simplesmente redistribuir os pesos: deverá exibir "evidência insuficiente" e reduzir a confiança global da análise.

4.1 Exemplos de interpretação

Uma postagem anônima sem documento de origem tende a receber baixa pontuação em fonte e verificabilidade. Uma reportagem que cita dados oficiais, mas não apresenta confirmação independente, pode obter pontuação intermediária. Uma publicação oficial do órgão responsável pelo dado apresenta forte proximidade da fonte primária, embora ainda deva ser examinada quanto a contexto, atualização e possíveis limitações.

5 Matriz de confiança do modelo e do processo

A segunda matriz avalia se o caminho usado pelo sistema para chegar ao resultado é tecnicamente confiável e transparente. Ela impede que uma interface bem apresentada oculte um modelo enviesado, descalibrado ou sem evidências suficientes.

Tabela 4: Matriz preliminar de confiança do modelo e do processo.

Dimensão	**Peso**	**Questão de auditoria**
Qualidade e representatividade dos dados	25%	Os dados são completos, atuais e adequados ao domínio, com vieses e duplicatas documentados?
Desempenho e generalização	20%	O modelo funciona por tema, período, fonte e grupo, inclusive em dados externos?
Calibração e incerteza	20%	A confiança prevista corresponde à frequência observada e casos fora de distribuição são sinalizados?
Transparência metodológica	15%	Versão, critérios, limitações e processo de atualização são compreensíveis e auditáveis?
Rastreabilidade das evidências	15%	Cada afirmação da resposta pode ser associada à sua fonte e ao trecho utilizado?
Correção e supervisão humana	5%	Há contestação, registro de mudanças e encaminhamento de casos ambíguos?
Total	**100%**	O resultado mede confiança operacional, não verdade factual.

O sistema só deve exibir uma avaliação consolidada quando ambas as matrizes atingirem requisitos mínimos. Uma notícia com boas fontes não compensa um processo opaco; da mesma forma, um modelo bem calibrado não transforma ausência de evidências em certeza factual.

6 Métodos de inteligência artificial

A investigação deve comparar métodos simples, auditáveis e avançados antes de escolher uma arquitetura. O primeiro objetivo é criar uma referência confiável, e não maximizar uma métrica isolada.

Tabela 5: Métodos candidatos e papéis no sistema.

Método	Uso possível	Cuidado principal
Classificadores supervisionados	TF–IDF com Regressão Logística ou SVM como baseline de classificação textual.	Podem aprender atalhos de fonte, tamanho e vocabulário editorial.
Redes neurais e Transformers	Capturar relações contextuais e realizar *fine-tuning* em português.	Exigem avaliação externa, explicabilidade e controle de custo.
Agrupamento e similaridade	Localizar notícias relacionadas, duplicatas e versões da mesma alegação.	Similaridade textual não implica concordância factual.
Recuperação de informação / RAG	Buscar checagens anteriores, documentos e fontes primárias para fundamentar a resposta.	A qualidade depende do índice, da atualidade e da rastreabilidade das fontes.
Modelos de linguagem	Resumir evidências, comparar versões e gerar perguntas de investigação.	Podem alucinar; toda afirmação relevante precisa de referência verificável.

O uso local ou remoto do modelo deverá ser decidido após avaliar privacidade, latência, custo, capacidade computacional e necessidade de atualização. Conteúdos submetidos por usuários podem conter dados pessoais ou informações sensíveis; por isso, retenção e compartilhamento precisam ser mínimos e explicitamente informados.

6.1 Dados, vieses e avaliação

Dados incompletos, desbalanceados ou originados de poucas fontes podem induzir o modelo a associar estilo, domínio, autor ou período ao rótulo. A preparação deverá auditar duplicatas, conflitos de classe, distribuição temática, datas, domínios e marcadores editoriais antes do treinamento. A divisão entre treino e teste deverá agrupar versões da mesma notícia e incluir avaliações por tempo e por fonte.

Além de Accuracy, devem ser considerados Precision, Recall, F1, Macro-F1, matriz de confusão e métricas de calibração. Comparações por tema, fonte e período são necessárias para revelar desempenho desigual. A probabilidade produzida pelo classificador deve ser identificada como *confiança estatística do modelo*, nunca como porcentagem objetiva de verdade.

7 Proposta de produto

O produto será um site de apoio à verificação. O usuário fornece uma notícia ou endereço e recebe um painel de investigação, em vez de um veredito isolado.

7.1 Fluxo principal

1. **Entrada:** texto, título ou URL da informação.
2. **Identificação:** autoria, domínio, data, alegação principal e possíveis fontes originais.
3. **Busca:** documentos, checagens e publicações independentes relacionadas.

4. **Análise:** aplicação dos critérios das matrizes e estimativa de incerteza.
5. **Apresentação:** visão por dimensão, evidências favoráveis e contrárias e limitações.
6. **Ação do usuário:** acesso às fontes, perguntas sugeridas, comentários e avaliação da utilidade da verificação.

7.2 Elementos da interface

- painel com as dimensões de confiança, sem reduzir toda a análise a uma única cor;
- lista de fontes, autoria, data, trechos relevantes e relação com a alegação;
- separação visual entre evidências favoráveis, contrárias e inconclusivas;
- indicação explícita de ausência de dados, conflitos e limitações do modelo;
- histórico de correções e opção de contestação com nova evidência;
- filtros temáticos, como política, ciência, saúde e esportes;
- avaliação da qualidade da verificação e espaço de comentários moderado;
- ranking de veículos apenas quando os critérios, período e cobertura forem transparentes.

Mensagem recomendada

Esta análise é um apoio à verificação, não uma decisão final. Consulte as evidências, considere o contexto e compare fontes antes de formar sua conclusão.

8 Questões orientadoras da investigação

8.1 Usuário

Como as pessoas verificam uma informação atualmente? O que as faz confiar ou desconfiar? Em qual etapa a IA pode apoiar a verificação? Que formato de explicação estimula consulta às fontes em vez de aceitação automática?

8.2 Modelo

Quais características podem ser utilizadas sem transformar fonte, autor ou estilo em atalhos indevidos? Como apresentar evidências em vez de apenas uma classe? Como calibrar a confiança, reconhecer casos fora do domínio e reduzir vieses?

8.3 Dados

Como identificar dados incompletos, enviesados, duplicados ou contraditórios? Quais grupos e períodos estão sub-representados? Como a qualidade da coleta altera as respostas? Qual é a unidade correta de análise: alegação, notícia, checagem ou publicação?

8.4 Ética e autonomia

Até que ponto uma recomendação de IA deve influenciar o usuário? Como evitar automação da confiança? Como preservar privacidade, possibilidade de contestação e acesso a versões divergentes? Quais situações exigem revisão humana?

9 Plano de desenvolvimento e validação

Tabela 6: Etapas propostas para o projeto.

Etapa	Objetivo	Entrega principal
1	Descoberta com usuários	Formulário, entrevistas e definição de público, necessidades e riscos de interpretação.
2	Auditoria de dados	Inventário, qualidade, vieses, duplicatas, taxonomias e critérios de inclusão.
3	Critérios e pesos	Matrizes revisadas por especialistas, comparações AHP e regras para evidência insuficiente.
4	Protótipo de IA	Baselines, recuperação de fontes, calibração e avaliação por tema, tempo e domínio.
5	Protótipo de interface	Testes de compreensão do score, evidências, incerteza e estímulo ao pensamento crítico.
6	Piloto e governança	Monitoramento, correções, documentação, supervisão humana e política de atualização.

Critérios de sucesso devem incluir não apenas desempenho do classificador, mas também capacidade do usuário de identificar a fonte, compreender a incerteza, distinguir previsão de evidência e realizar ao menos uma verificação independente. O produto falha em seu propósito se um score aparentemente preciso aumentar a confiança cega.

10 Limitações e decisões em aberto

- A definição de "confiabilidade" depende do tipo de conteúdo e não equivale automaticamente a veracidade.
- Os pesos das matrizes ainda são preliminares e precisam de validação empírica e especializada.
- A avaliação automática de autoridade e histórico de uma fonte pode reproduzir vieses institucionais.
- Notícias emergentes podem não possuir corroboração suficiente; ausência de confirmação não prova falsidade.
- Linguagem emocional ou erros ortográficos são sinais fracos e não devem dominar a classificação.
- Rankings públicos de veículos exigem metodologia, período de análise, direito de resposta e política de correção.
- O projeto ainda precisa decidir entre modelos locais, serviços externos ou uma arquitetura híbrida.

11 Conclusão

A proposta do Grupo 3 posiciona a IA como instrumento de investigação, não como árbitro da verdade. O valor do sistema está em organizar fontes, evidências, contexto, corroboração e incerteza de modo compreensível e auditável. As duas matrizes de confiança ajudam a separar a qualidade da informação da qualidade do modelo e do processo utilizado para analisá-la.

A próxima etapa recomendada é validar o problema com usuários, revisar as dimensões com especialistas em jornalismo e ciência de dados e testar os pesos por AHP. Em paralelo, a equipe deve construir baselines transparentes e uma camada de recuperação de evidências. O resultado esperado não é eliminar o julgamento humano, mas oferecer melhores condições para que cada pessoa exerça seu pensamento crítico.

Referências

[1] International Fact-Checking Network. *Code of Principles*. Poynter Institute. Disponível em: https://ifcncodeofprinciples.poynter.org/.

[2] Agência Nacional de Aviação Civil. *Análise Hierárquica de Processos (AHP): material de referência*. Disponível em: https://www.gov.br/anac/pt-br/assuntos/meio-ambiente/arquivos/Anexo3.pdf.